

Modélisation décisionnelle

Concevoir la base de données
pour les traitements **OLAP**

Thibault BOURCY



Chapitre 1

Avant-propos

1. But de l'ouvrage.	11
2. De multiples concepts et quelques outils	12
2.1 Une modélisation indispensable et des outils utiles.	12
2.2 Un concept, de multiples modèles.	13
3. Rapports versus décisionnel.	14
4. Le quiproquo du Big Data	15
5. Utilisateurs visés.	16
6. À propos du contenu	16
6.1 Technologies utilisées.	16
6.2 Code couleur pour les schémas	17

Chapitre 2

Aborder le décisionnel

1. Quid des termes décisionnels.	19
1.1 De nombreux termes pour de nombreux concepts	19
1.2 Détails par catégorie.	19
1.2.1 Le projet : décisionnel, aide à la décision ou la Business Intelligence	19
1.2.2 Le système d'information : SID ou système d'information décisionnel.	20
1.2.3 Les données : base de données décisionnelle relationnelle, entrepôt de données et magasin de données.	20
1.2.4 La modélisation spécifique : base de données multidimensionnelle, OLAP, cubes	20
1.2.5 Le chargement des données : ETL, intégration.	21
1.2.6 La restitution de la donnée : reporting, restitution, rapports, états, tableaux de bord, analyse, reporting ad hoc	21
1.3 Synthèse	22

2 ————— **Modélisation décisionnelle**

Concevoir la base de données pour les traitements OLAP

2.	La justification du décisionnel	23
2.1	Des données et un besoin déjà présents	23
2.1.1	Un besoin analytique	23
2.1.2	Bien qualifier ce besoin.	24
2.2	La réponse à un besoin métier	24
2.3	Une nécessité technique.	26
2.4	Une nécessaire historisation	29
2.5	Nécessaire mais dispensable.	31
3.	Mise en œuvre du projet	31
3.1	Les étapes	31
3.2	Découper le projet	32
4.	Identification du besoin	33
4.1	Identifier les utilisateurs cibles	33
4.2	Reprise de l'existant	34
4.2.1	Reprise en l'état.	34
4.2.2	Identification des éléments clés.	34
4.3	Demandes récurrentes	35
4.4	Identification des nouveaux besoins	35
4.5	Formaliser le besoin	36
4.5.1	Matrice des besoins	36
4.5.2	Détails complémentaires	36
4.6	La réalité	38

Chapitre 3

Repenser la donnée

1.	De la technique au métier	39
2.	Des "applications" aux "objets"	39
3.	De l'événement à la période	41
4.	Du transactionnel à l'analyse.	42
5.	De l'exhaustivité à la simplicité	44

Chapitre 4

Comprendre les spécificités du décisionnel

1. Le multidimensionnel : hiérarchiser la donnée	45
1.1 Les dimensions	45
1.2 Les cubes	48
1.3 Densité d'un cube	52
1.4 Les technologies de cubes	53
1.5 L'interaction avec le datawarehouse	54
1.6 Un langage spécifique : le MDX	54
1.7 Les modes de stockage	57
1.7.1 Différents modes de stockage	57
1.7.2 MOLAP	58
1.7.3 ROLAP	59
1.7.4 HOLAP	60
1.7.5 Synthèse et choix	63
1.7.6 Autres technologies	64
2. Les fondamentaux de la base de données relationnelle	65
2.1 Le rôle de la base de données relationnelle	65
2.2 La dénormalisation	66
2.2.1 Principe	66
2.2.2 Dénormaliser les référentiels	67
2.2.3 Dénormaliser les transactions	70
2.3 Pourquoi ne pas tout dénormaliser ?	73
2.4 Les modèles de données	75
2.4.1 Dimensions versus référentiels	75
2.4.2 Modèle en étoile	77
2.4.3 Modèle en flocon	80
2.4.4 Choix du modèle	81
2.4.5 Modèle en galaxie ou constellation	86

4 **Modélisation décisionnelle**

Concevoir la base de données pour les traitements OLAP

Chapitre 5

Identifier le projet

1. Entrepôts et magasins de données.	87
1.1 Deux éléments distincts.	87
1.2 Identification des caractéristiques.	90
2. Méthodologies de conception	92
2.1 Inmon : de l'entrepôt aux magasins	92
2.2 Kimball : des magasins à l'entrepôt	93
2.3 Une même vision cible	94
2.4 Choisir une méthode et Middle-Out	95
2.5 Le piège de la technique	97
3. Formaliser l'entrepôt et les magasins de données.	104
3.1 Les différents rôles de l'entrepôt de données	104
3.2 Les multiples concepts du magasin de données	106
3.2.1 Les limites de la définition de base	106
3.2.2 Le magasin de données comme nécessité technique	107
3.2.3 Ordonnancement avec l'entrepôt	111
3.2.4 Cardinalités entre datamarts et restitutions	115
4. La base de données opérationnelle.	124
4.1 L'ODS	124
4.2 La Staging Area ou Landing Zone	125
5. Identifier les contraintes	126
5.1 Avant-propos	126
5.2 Contraintes technologiques.	127
5.2.1 Processus de choix des technologies	127
5.2.2 Choix d'une solution pour la modélisation de la base de données relationnelle	129
5.2.3 Choix d'une solution pour la modélisation des cubes	131
5.3 Contraintes techniques	133
5.3.1 Accès aux données	133
5.3.2 Espace disque	133
5.3.3 Exploitation	133

5.4	Contraintes projet	134
5.4.1	Attentes utilisateurs	134
5.4.2	Planning	134
5.4.3	Normes et modélisation	135
5.4.4	Sécurité	135

Chapitre 6

Concevoir le modèle

1.	Identifier les étoiles	137
1.1	L'importance des étoiles	137
1.2	Structuration ascendante	138
1.3	Identifier un fait	142
2.	Formaliser une dimension	145
2.1	Dimension référentielle et dimension de faits	145
2.2	Les hiérarchies	148
2.2.1	Identifier une hiérarchie	148
2.2.2	Construire une hiérarchie	150
2.2.3	Ascendance unique	152
2.2.4	Homogénéité des niveaux	158
2.2.5	Profondeur limitée et prédéfinie	161
2.2.6	Les éléments communs entre les branches	164
2.3	Dimension basée sur les faits	166
2.3.1	Dans la base de données relationnelle	166
2.3.2	Dans la base de données multidimensionnelle	170
2.3.3	Alternatives à l'absence de référentiel	172
2.4	Structure d'une table de dimension	173
2.4.1	Identifiants techniques	173
2.4.2	Codes, libellés et attributs fonctionnels	174
2.4.3	Structure des tables	176
2.5	Le cas particulier de la dimension temps	178

6 **Modélisation décisionnelle**

Concevoir la base de données pour les traitements OLAP

3.	Formaliser les indicateurs.	181
3.1	Différents termes et différents concepts.	181
3.2	Indicateur intensif et indicateur extensif	183
3.3	Indicateurs calculés simples.	186
3.4	Indicateurs calculés complexes	187
4.	Identifier les données	194
4.1	Dans la base de données décisionnelle	194
4.2	Dans la base de données opérationnelle	198
5.	Formaliser la table de faits	201
5.1	La structure type d'une table de faits	201
5.2	Les sources des tables de faits	202
5.3	Consolidation de tables de faits.	203
5.4	Contraintes techniques	207
5.5	La gestion des valeurs nulles	208
5.6	Granularité de la table de faits.	209
5.6.1	Finesse des données	209
5.6.2	Impact sur la volumétrie	210
6.	Formaliser la table d'agrégats.	212
6.1	Rôle et structure d'une table d'agrégats	212
6.2	Utilisation de filtres	213
6.3	Utilisation d'agrégats de dimension	214
6.3.1	Méthodes et limites	214
6.3.2	Impacts sur la granularité	218
6.4	Utilisation d'agrégats de faits.	218
6.5	Suppression de dimension	220
6.6	Contraintes techniques	222
7.	Nommer les objets	223
8.	Schéma synthétique des flux et types d'objets.	224
8.1	Entrepôt en flocon et magasins en étoile	224
8.2	Entrepôt en étoile et magasins en étoile	225
8.3	Entrepôt en flocon et magasins en flocon.	225

Chapitre 7

Historiser les données

1. Les raisons de l'historisation	227
2. Historisation des dimensions.	229
2.1 Une évolution de la réalité métier	229
2.2 Dimension à évolution lente	230
2.2.1 Les méthodes courantes	230
2.2.2 Ajout d'une nouvelle ligne	230
2.2.3 Ajout d'une nouvelle colonne	241
2.3 Dimension à évolution rapide	245
2.4 Choix de la période	246
3. Historisation des faits	248
3.1 Identification des faits	248
3.2 Problématique et historisation des faits	248
4. Historiser ou corriger ?	252
4.1 Identification du contexte analytique de la donnée.	252
4.2 Le temps des choix et concessions.	259
5. Initialisation d'un système historisé	259
5.1 Des données historiques mais non historisées	259
5.2 Utiliser le contexte initial du SID	260
5.3 Autres méthodes.	262
6. Durée d'historisation idéale	263
6.1 Entre contrainte technique et utilité métier.	263
6.2 Historisation des indicateurs agrégés	269
7. Remarques complémentaires.	270
7.1 Reconsidérer le problème	270
7.2 Calcul sur une période	270
7.3 Impact sur la volumétrie	271
7.4 Dates d'effet, saisie et chargement	272

8 ————— **Modélisation décisionnelle**

Concevoir la base de données pour les traitements OLAP

Chapitre 8

Enrichir le modèle

1. Problématique de conception des objets	275
1.1 Limiter le découpage des objets	275
1.2 Les plages de dates dans les faits	276
1.2.1 Périodes basiques	276
1.2.2 Chevauchements de périodes	285
1.3 L'utilisation d'une mesure comme dimension	293
1.4 Les indicateurs distinctifs.	295
1.5 Transformer un attribut en dimension.	297
1.6 La relation many-to-many dans une dimension.	301
1.6.1 Présentation du problème	301
1.6.2 Répartir les parents dans plusieurs hiérarchies.	302
1.6.3 Répartir les parents dans plusieurs dimensions	304
1.7 Diviser une étoile en plusieurs étoiles	307
1.7.1 En enlevant une dimension	307
1.7.2 En rajoutant une dimension	310
1.7.3 Influence des données sources	311
2. Problématiques de la dimension temps.	312
2.1 Les valeurs par défaut sur la dimension temps.	312
2.2 Les dimensions temps métier.	313
2.3 L'utilisation parcimonieuse des dates	318
2.4 L'analyse sur les heures.	321
3. Problèmes de granularité des transactions reçues.	324
3.1 Description du problème	324
3.2 Des données opérationnelles trop fines.	325
3.3 Des données opérationnelles trop larges.	326
3.4 Des données opérationnelles hétérogènes.	330
4. Problématiques des référentiels	330
4.1 Stratégies de rejet	330
4.2 Utilisation d'alias	333
4.3 Les référentiels non analytiques	335

4.4	Les référentiels autoalimentés	337
4.4.1	Justification et création d'un référentiel autoalimenté .	337
4.4.2	Regroupements et hiérarchies des référentiels autoalimentés	339
5.	Problématiques de correction des faits	342
5.1	Création d'un flux de correction	342
5.2	Corriger une mesure	343
5.3	Corriger une ventilation	344

Chapitre 9

Charger les données

1.	Le choix de la solution d'intégration	347
1.1	SQL versus ETL	347
1.2	Choix techniques	348
1.2.1	Performances	348
1.2.2	Fonctions avancées	348
1.2.3	Formats de données	348
1.3	Une interface explicite	349
1.4	Compétences	350
1.5	Bilan	350
2.	Chargement des éléments du modèle	351
2.1	Les différents types de chargements utilisables dans un SID .	351
2.1.1	Annule et Remplace	351
2.1.2	Insertion ou Mise à jour (alias UPSERT)	352
2.1.3	Insertion des modifications (alias INSERT)	352
2.2	Utilisation des types de chargements dans le SID	353
2.2.1	Synthèse par flux	353
2.2.2	L'effet boule de neige dans les flux transactionnels	354
2.2.3	L'évolutivité du contexte	358

10 ————— **Modélisation décisionnelle**

Concevoir la base de données pour les traitements OLAP

3. Ordonnancement des éléments	360
3.1 Dépendances des objets	360
3.2 Compartimentage des objets	363
3.3 Fréquence d'intégration	364
4. En dehors des phases d'exploitation	365
4.1 Chargement initial	365
4.2 Reprises de données	366

Chapitre 10

Optimiser le modèle

1. Identifier les optimisations	367
2. Optimisation de la base de données relationnelle	368
2.1 Utilisation des index	368
2.2 Utilisation des partitions	371
2.3 Types de colonnes	374
2.4 Utilisation des vues et tables temporaires	375
2.5 Suppression des contraintes	378
3. Optimisation de l'utilisation du serveur ETL	379

Glossaire	381
-----------------	-----

Index	387
-------------	-----

Chapitre 2

Aborder le décisionnel

1. Quid des termes décisionnels

1.1 De nombreux termes pour de nombreux concepts

S'attaquer au décisionnel, c'est faire face à de nombreux concepts et de nombreux termes, parfois mal utilisés, parfois évoquant la même chose et souvent associés à des concepts différents suivant la personne qui l'utilise.

Si certains des termes évoqués ci-dessous ne sont actuellement pas connus du lecteur, ils seront en revanche par la suite utilisés dans l'ouvrage.

1.2 Détails par catégorie

1.2.1 Le projet : décisionnel, aide à la décision ou la Business Intelligence

Ces expressions évoquent toutes les trois l'ensemble des méthodes et applications mises en œuvre pour répondre à un besoin analytique sur la base de données, non exploitable à ce but en l'état, pour cause de format non explicite ou de volumétrie importante, par exemple.

20 ————— **Modélisation décisionnelle**

Concevoir la base de données pour les traitements OLAP

Si la "Business Intelligence", parfois traduite par "intelligence d'affaires, et son acronyme "BI" sont juste censés être l'équivalent de "aide à la décision" en anglais, ces termes sont parfois utilisés pour désigner la seule couche de restitution visuelle de la donnée, quand ce terme désigne en réalité l'ensemble des couches du décisionnel. Bien qu'inexacte, cette utilisation courante trouve ses racines dans la genèse du décisionnel, lorsque les seuls logiciels dits de "BI" ne pouvaient alors que proposer la production de restitutions.

1.2.2 Le système d'information : SID ou système d'information décisionnel

Le système d'information décisionnel – SID étant son acronyme – est quant à lui l'ensemble des solutions informatiques composant le décisionnel : bases de données, applications d'intégration de données, de restitution...

1.2.3 Les données : base de données décisionnelle relationnelle, entrepôt de données et magasin de données

Une base de données décisionnelle comporte a minima un entrepôt de données (même dans un contexte francophone, le terme anglais de "datawarehouse" est couramment employé) et peut compter des magasins de données (le terme anglais "datamarts" s'emploie également en français). Si la différence entre ces deux objets sera explicitée plus loin dans l'ouvrage, ils constituent la base de données spécifiquement conçue et alimentée pour le décisionnel. La grande majorité de cet ouvrage est dédiée à leur modélisation spécifique.

Techniquement, la base de données décisionnelle est ici relationnelle, c'est-à-dire qu'elle s'appuie sur les technologies classiques de base de données, les SGBDR (serveurs de gestion de bases de données relationnelles).

1.2.4 La modélisation spécifique : base de données multidimensionnelle, OLAP, cubes

Contrairement au point précédent, la base de données multidimensionnelle est une forme de stockage reposant sur une technologie propre au décisionnel et donc, différente du relationnel. On parle également de base de données "OLAP" (*OnLine Analytical Processing* traduit en français par "traitement analytique en ligne"). Ainsi, un "cube" est une base de données OLAP, et de fait, une base de données multidimensionnelle.

Les cubes sont parfois considérés comme des datamarts, ce qui – à défaut d'être faux – est ambigu. Il conviendra alors de préciser "datamarts multidimensionnels" pour les différencier des "datamarts relationnels" évoqués dans la partie précédente.

Le terme OLAP définit plus largement le multidimensionnel, c'est-à-dire la manipulation de données par agrégat et axes d'analyse. Ainsi, pour définir un cube, il sera préférable d'utiliser le terme complet de "base de données OLAP" pour ne pas laisser d'ambiguïté.

1.2.5 Le chargement des données : ETL, intégration

L'intégration de données est le fait de charger les données depuis une ou plusieurs sources de données externes dans les bases de données décisionnelles.

L'ETL (pour *Extract-Transform-Load*) est un outil spécifique qui sert à réaliser cette intégration.

1.2.6 La restitution de la donnée : reporting, restitution, rapports, états, tableaux de bord, analyse, reporting ad hoc

Il s'agit là de termes différents pour évoquer les différentes formes de restitution de la donnée aux utilisateurs.

Si quelques termes sont redondants, on oppose tout de même, d'une part, les restitutions fixes, qui sont les rapports préformatés dont le contenu ou le périmètre peuvent être mis à jour, mais dont la structure reste fixe, et d'autre part, les rapports ad hoc, permettant à l'utilisateur de construire ou faire évoluer totalement un rapport sur la base de données préconçues à cet usage, à la manière d'un tableau croisé dynamique.

En termes de restitution, les tableaux de bord réunissent quelques indicateurs majeurs et sont attendus comme plus succincts et moins détaillés que les reportings.


22

Modélisation décisionnelle

Concevoir la base de données pour les traitements OLAP

1.3 Synthèse

Le schéma ci-dessous repositionne chaque terme derrière un élément et le replace dans son contexte :



2. La justification du décisionnel

2.1 Des données et un besoin déjà présents

2.1.1 Un besoin analytique

Le système d'information décisionnel (noté SID par la suite) répond-il à un besoin existant ou bien le produit crée-t-il lui-même le besoin ? Les deux. Le SID répond à un besoin déjà existant, mais sa mise en place va appeler de nouveaux besoins.

Dans la réalité des faits, la mise en place d'un SID permet – souvent – uniquement de pérenniser, fiabiliser, simplifier un processus déjà existant. Un manager demande régulièrement un rapport d'activité ? Les analystes métier demandent des tableaux de données ? Il s'agit bien de "décisionnel", et pourtant, ces demandes existaient bien avant le SID. Sauf que ces données ne peuvent être fournies que par des informaticiens travaillant sur les bases de données de l'entreprise.

Les limites sont explicites :

- Mauvaise réactivité : nécessite de demander l'information à une personne tierce.
- Coût humain : temps consommé par les informaticiens pour produire ces rapports ou listings.
- Coût matériel : impact de la génération de ces rapports et listings sur le système transactionnel.

Autre constat : si le besoin existe, les éléments de réponses aussi. En effet, puisque la DSI arrive à produire le rapport ou listing demandé, c'est que les données nécessaires existent bien quelque part dans l'entreprise : le décisionnel est donc une valorisation des données existantes ! Il n'est donc pas nécessaire (la plupart du temps) de créer de nouvelles données, c'est-à-dire une nouvelle application de saisie consommatrice de temps.

24 _____ **Modélisation décisionnelle**

Concevoir la base de données pour les traitements OLAP

2.1.2 Bien qualifier ce besoin

Comme évoqué dans l'avant-propos, le décisionnel ne doit pas être réduit à la production de restitutions puisqu'il s'accompagne de la mise en place de nombreux concepts et technologies. Sa mise en œuvre est donc souvent lourde et coûteuse et il convient donc de s'assurer que le décisionnel répond bien au besoin.

La restitution des données – sous forme de rapports, graphes ou de tableaux croisés dynamiques – est bien sûr la finalité du décisionnel mais elle n'en reste pas moins la face émergée de l'iceberg puisque les mécaniques de production de ces restitutions qualifieront le projet dans l'une ou l'autre catégorie. La donnée actuellement disponible permet-elle de répondre efficacement au besoin métier ? Si oui, un simple outil de reporting sera suffisant. Dans le cas contraire, la mise en place du décisionnel sera sûrement nécessaire.

Bien qualifier le projet permet, dans un sens, de ne pas s'engager sur un chantier démesuré quand la demande est simple. À l'opposé, et c'est le cas le plus récurrent, la mise en place d'un système décisionnel complet en lieu et place d'un simple outil de reporting est primordial, lorsque le besoin est réel. Même si cela peut sembler bien plus économe de prime abord, s'engager de force avec une solution plus "simpliste" que "simple", aboutit souvent sur une fastidieuse mise en place, des données peu fiables, et sur un outil peu réactif et difficile à faire évoluer. En effet, il faut parfois monter de véritables usines à gaz pour permettre à un outil de reporting de composer avec des données qui ne s'y prêtent pas.

2.2 La réponse à un besoin métier

Le sujet concerne deux questions distinctes :

- Pourquoi mettre en place une solution décisionnelle ?
- Pourquoi utiliser une modélisation décisionnelle ?

La seconde question est induite par la première, puisque la modélisation décisionnelle sera la réponse technique afférente à la réponse métier.